

# Series de tiempo como modelos lineales

Fernanda Mora  
7 noviembre, 2016




Diplomado de Minería de Datos  
para la toma de decisiones

# Contenido

- Introducción
- Estadística básica
  - Ejercicio práctico 1
- Modelos AR y MA
  - Ejercicio práctico 2
- Framework para modelos ARIMA

$$y = f(x_1, \dots, x_n)$$





# Introducción

# Preliminares

- Una **serie temporal** es una **sucesión de observaciones indexadas y ordenadas por el tiempo**
- Los datos pueden estar **espaciados a intervalos iguales** (más frecuentemente) o **desiguales**
- Ejemplos son: precio de acciones a lo largo del tiempo, medición signos vitales cada hora, PIB mensual.
- Es difícil imaginar una rama en la que no aparezcan datos que puedan ser considerados como series temporales: **Medicina, Meteorología, Economía, Finanzas, Logística.**

# Preliminares



# Preliminares

- El **análisis de series de tiempo** comprende métodos para analizar series con el fin de extraer información relevante
- El **pronóstico de series de tiempo** es el uso de un modelo para predecir valores futuros basados en datos previamente observados. Es en donde se encuentra la **mayor actividad** de series de tiempo.
- Pueden ser usadas en **variables de razón/continuas** o bien **discretas ó categóricas**.
- En una serie de tiempo cada observación tiene una **dependencia temporal**, el orden importa. En los otros datasets que hemos visto el orden no importaba.

# Preliminares

- Los métodos para análisis de series de tiempo se pueden dividir en: **con respecto a la frecuencia o con respecto al tiempo.**
- **Frecuencia:** Análisis espectral y análisis de wavelets.
- **Tiempo:** Auto-correlación y correlación cruzada.
- También se pueden dividir en **paramétricos y no paramétricos.**
- **No Paramétricos:** no asumen ninguna distribución subyacente, ni parámetros, estiman sin hacer supuestos obre los datos.

# Preliminares

- **Paramétricos:** asumen que el proceso estocástico estacionario tiene cierta distribución subyacente que puede ser descrita usando algunos parámetros (ej. modelos autorregresivos o de promedios móviles).
- También pueden dividirse en **lineales o no lineales**, y en **univariados o multivariados**.
- En esta clase estudiaremos **métodos paramétricos usando modelos lineales**.
- En la siguiente clase estudiaremos **métodos no paramétricos usando modelos no lineales**.



# Estadística básica

# Análisis de series de tiempo

## Proceso:

1. Visualizar la serie
2. Hacerla estacionaria
3. Graficar ACF/PACF y encontrar parámetros
4. Construir el modelo ARIMA
5. Predecir


# Series estacionarias

## Estadística descriptiva


Decimos que una **serie es estacionaria** cuando “**es estable a lo largo del tiempo**”

1. **Media constante a lo largo del tiempo.** Es decir, la **media** NO debe estar en función del tiempo.

Gráficamente: los valores de la serie tienden a oscilar alrededor de una media constante.



Stationary series



Non-Stationary series


# Series estacionarias

## Estadística descriptiva


Decimos que una **serie es estacionaria** cuando “**es estable a lo largo del tiempo**”

2. **Varianza constante a lo largo del tiempo.** Es decir, la **varianza** NO debe estar en función del tiempo.

Gráficamente: la variabilidad con respecto a esa media también permanece constante en el tiempo.



Stationary series



Non-Stationary series


A esta propiedad también se le conoce como **homocedasticidad** y también la vimos en **regresión lineal** (para los errores)

# Series estacionarias


## Estadística descriptiva

Decimos que una **serie es estacionaria** cuando “**es estable a lo largo del tiempo**”

3. **Covarianza constante.** Covarianza del término  $i$ -ésimo y del término  $(i+m)$  NO deben ser una función del tiempo.



Stationary series



Non-Stationary series

# Procesos estocásticos estacionarios

- Un **proceso estocástico** se describe como una sucesión de variables aleatorias (datos) que evolucionan en el tiempo.
- Las **series temporales** se definen como un **caso particular de los procesos estocásticos**.
- Un proceso estocástico se dice que es estacionario si su **media** y su **varianza** son **constantes en el tiempo**, y si el valor de la covarianza entre dos periodos depende solamente de la distancia o rezago entre estos y no del tiempo en el cual se ha calculado la covarianza:

Si una serie de tiempo es **estacionaria** entonces su media, su varianza y son **invariantes en el tiempo**.



Sea  $X_t$  una serie de tiempo entonces con estas propiedades:

$$\text{Media} \quad E(X_t) = E(X_{t+k}) = \mu$$

$$\text{Varianza} \quad V(X_t) = V(X_{t+k}) = \sigma^2$$


$$\text{Covarianza} \quad \gamma_k = E[(X_t - \mu)(X_{t+k} - \mu)]$$

# Procesos estocásticos estacionarios

- ¿Para qué queremos esto?
- **Necesitamos series estacionarias** para poder construir estos modelos.
- ¿Qué pasa cuando una serie **no es estacionaria**?
- ¡La hacemos (o tratamos de hacerla) estacionaria!
- Hay varios métodos para lograr esto.

# Ejemplo

## Caminata aleatoria




- La **caminata aleatoria** es el ejemplo más básico de proceso estocástico:  $X(t) = X(t-1) + e(t)$ ,  $e(t)$  es **ruido blanco**.  $\varepsilon_t \sim N(0, \sigma^2)$   $cov(\varepsilon_{t_i}, \varepsilon_{t_j}) = 0 \quad \forall t_i \neq t_j$
- ¿Cómo **predecir la posición de la niña** con respecto al tiempo, i.e.  $X(t)$ ? Cada vez es más difícil.
- $X(t) = X(0) + [e(1)+e(2)+e(3)+...+e(t)]$
- ¿La serie es estacionaria?
  - $E(X(t))=X(0) \rightarrow$  **constante**
  - $Var(X(t))= t * Var(e(t)) = t*constante \rightarrow$  **Depende del tiempo**
  - La **caminata aleatoria NO es estacionaria**




# Ejemplo


## Caminata aleatoria



- ¿Cómo hacerla estacionaria?
- Sea Rho un coeficiente y haremos  $X(t) = \text{Rho} * X(t-1) + \text{Er}(t)$
- La idea es ver si con esto podemos hacer la serie estacionaria




Rho = 0




Rho = 0.5

# Ejemplo


## Caminata aleatoria



- ¿Cómo hacerla estacionaria?
- Sea  $\text{Rho}$  un coeficiente y haremos  $X(t) = \text{Rho} * X(t-1) + \text{Er}(t)$
- ¿Cómo escogemos la  $\text{Rho}$  adecuada?



$\text{Rho} = 0.9$



$\text{Rho} = 0.5$

# Ejemplo

## Test de estacionariedad Dickey Fuller

- Lo anterior se puede enunciar formalmente en una **prueba de hipótesis**.
- $X(t) = \text{Rho} * X(t-1) + e(t) \Rightarrow X(t) - X(t-1) = (\text{Rho} - 1) X(t-1) + e(t)$
- Tenemos que probar si  $\text{Rho} - 1$  es significativamente diferente de cero o no.
- Si la hipótesis nula se rechaza entonces tenemos una **serie de tiempo estacionaria**.
- Estos procesos son claves para tener un **modelo correcto**.

# Estacionariedad

## Métodos

1. **Quitar la tendencia:** Removemos la tendencia de la serie de tiempo.

Por ejemplo, si la ecuación es  $x(t) = (\text{media} + \text{trend} * t) + \text{error}$ , sólo removemos la parte del paréntesis y construimos un modelo para lo demás.

- 2.


- 3.

# Modelos AR y MA

# Ejemplo

## Modelo AR (autoregresivo)

- Supongamos que la demanda es  $x(t) = \alpha * x(t-1) + \text{error}(t)$
- Esto se conoce como modelo **AR(1)** (autorregresivo de orden 1)
- Buscamos  $\alpha$  que minimice el error.
- AR no siempre es estacionario (AR(1), si  $|\alpha| > 1$  entonces no)




Propiedad de **inercia** del modelo AR:  
Cualquier shock se **diluirá a través del tiempo**

$$\text{AR}(p): X_t = c + \sum_{i=1}^p \varphi_i X_{t-i} + \varepsilon_t$$

# Ejemplo

## Modelo MA (de promedios móviles)

- $x(t) = \text{beta} * \text{error}(t-1) + \text{error}(t)$
- Esto se conoce como modelo **MA (1)** (moving average de orden 1)
- Ejemplo: demanda de un producto nuevo



Propiedad de **recuperación inmediata del modelo MA**. El efecto se diluye de inmediato.

$$\text{MA}(q): X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

# Diferencias entre los modelos AR y MA

- La diferencia principal es la **correlación** de la serie de tiempo en diferentes instantes de tiempo
- $\text{Corr}(x(t), x(t-n)) = 0$  para **MA con  $n > \text{orden}$**
- $\text{Corr}(x(t), x(t-n))$  **decrece** conforme  $n$  crece para **AR**
- La **gráfica de correlación** puede decirnos el orden del modelo MA.
- Una vez que el proceso es **estacionario**, hay que **investigar si es un proceso AR o MA**.
- Posteriormente hay que investigar el **orden del proceso**.



# Análisis de series de tiempo



¿Qué modelo es: AR o MA?

- Usamos **gráfica de correlación total**, también llamada función de autocorrelación ó ACF)
- ACF grafica la **correlación total entre diferentes lags**: estamos interesados en la correlación de  $x(t)$  con  $x(t-1)$ ,  $x(t-2)$ ,... etc.
- En un modelo MA de lag  $n$ ,  **$\text{corr}(x(t), x(t-n-1))=0$** . Entonces es fácil encontrar el lag para estos modelos.
- Para un modelo **AR la correlación irá bajando sin cortar**.
- ¿Qué hacemos con estos modelos?
- Usamos la **función de correlación parcial de cada lag**, y **cortará después del orden del proceso AR**.

# Análisis de series de tiempo

¿Qué modelo es: AR o MA?

- **Por ejemplo**, si tenemos un modelo AR(1), si excluimos el efecto del 1er lag (i.e.  $x(t-1)$ ), el segundo lag ( $x(t-2)$ ) es independiente de  $x(t)$ .
- Entonces esta **función de correlación parcial (PACF)** caerá estrepitosamente después del 1er lag.





La línea azul muestra valores significativamente distintos de cero. Claramente la gráfica tiene un corte en la función de PACF después del segundo lag. Esto significa que es a lo más un AR(2).

# Análisis de series de tiempo

¿Qué modelo es: AR o MA?

- **Por ejemplo**, si tenemos un modelo AR(1), si excluimos el efecto del 1er lag (i.e.  $x(t-1)$ ), el segundo lag ( $x(t-2)$ ) es independiente de  $x(t)$ .
- Entonces esta **función de correlación parcial (PACF)** caerá estrepitosamente después del 1er lag.



Claramente la gráfica tiene un corte en la gráfica de ACF después del segundo lag, lo que significa que a lo más es un MA(2).

# Análisis de series de tiempo

## Proceso:

1. Visualizar la serie
2. Hacerla estacionaria
3. Graficar ACF/PACF y encontrar parámetros
4. Construir el modelo ARIMA
5. Predecir

# Estacionariedad

## Métodos

2. **Diferenciar:** es la técnica más común para quitar la no estacionariedad. Tratamos de modelar las diferencias de los términos.

Por ejemplo,  $x(t) - x(t-1) = \text{ARMA}(p, q)$

Esta diferenciación se llama **integración: AR(I)MA**. Así, tenemos tres parámetros:

$p \rightarrow \text{AR}$

$d \rightarrow \text{I}$

$q \rightarrow \text{MA}$

# Estacionariedad

## Métodos

2. **Diferenciar:** es la técnica más común para quitar la no estacionariedad. Tratamos de modelar las diferencias de los términos.

Por ejemplo,  $x(t) - x(t-1) = \text{ARMA}(p, q)$

Esta diferenciación se llama **integración**: **AR(I)MA**. Así, tenemos tres parámetros: **p** -> **AR**, **d** -> **I**, **q** -> **MA**

3. **Estacionalidad:** se puede incorporar directamente al modelo **ARIMA**.

Los modelos con menor AIC (aikake criterion), BIC (bayes info criterion) serán los elegidos.

# Análisis de series de tiempo

## Proceso:

1. Visualizar la serie
2. Hacerla estacionaria
3. Graficar ACF/PACF y encontrar parámetros
4. Construir el modelo ARIMA
5. Predecir

# Análisis de series de tiempo

## Proceso:

1. Visualizar la serie
2. Hacerla estacionaria
3. Graficar ACF/PACF y encontrar parámetros
4. Construir el modelo ARIMA
5. Predecir



# Gracias